TRABAJO PRÁCTICO 04

Clustering (K-Medias y algoritmos jerárquicos)

Presentación

Esta guía acompaña la Clase Clustering y se **resuelve en papel**, con calculadora. Los seis ejercicios van de las medidas de distancia a los algoritmos y terminan evaluando el resultado del linkage.

Objetivos. Al terminar la guía, el estudiante debería poder:

- calcular distancias y similitudes para variables numéricas, binarias y categóricas, y explicar por qué hay que normalizar;
- ejecutar K-Means paso a paso y reconocer un óptimo local;
- construir dendrogramas con distintos linkages y comparar los agrupamientos que producen;
- evaluar un agrupamiento con la suma de cuadrados, el método del codo y el coeficiente de silueta.

Consignas generales.

- Redondear los resultados a 2 decimales, salvo que se indique otra cosa.
- Dejar escritos los cálculos intermedios: interesa el procedimiento, no solo el resultado.
- Si no se indica otra medida, la distancia es la Euclídea.
- En K-Means, si un punto está a la misma distancia de dos centroides, se asigna al cluster de menor número.

Ejercicio	Tema	Clase 8
1	Distancias numéricas y normalización	Sección 2
2	Jaccard y variables categóricas	Sección 2
3	K-Means a mano	Sección 3
4	Óptimos locales y método del codo	Secciones 3 y 5
5	Jerárquico: single vs. complete linkage	Sección 4
6	Average linkage y coeficiente de silueta	Secciones 4 y 5

Ejercicio 1: distancias numéricas y normalización

Repaso. La familia Minkowski mide la distancia entre dos puntos i y j con p variables numéricas. Con h = 1 es la distancia de Manhattan y con h = 2, la Euclídea.

d(i, j) = (|x(i,1) − x(j,1)|^h + |x(i,2) − x(j,2)|^h + … + |x(i,p) − x(j,p)|^h)^(1/h)

donde x(i,f) es el valor de la variable f en el punto i.

La normalización min-max lleva cada variable al intervalo [0, 1]:

x' = (x − mín) / (máx − mín)

Parte A. Dados los puntos A = (1, 1), B = (4, 5) y C = (6, 1):

1. Calcular las distancias Euclídea, Manhattan y Minkowski con h = 3 para los tres pares (A-B, A-C, B-C).
2. Para A-B y A-C, la distancia Euclídea da el mismo valor. ¿Ocurre lo mismo con Manhattan? Explicar por qué con un dibujo en el plano.
3. Verificar la desigualdad triangular con las distancias Euclídeas: ¿d(A,C) ≤ d(A,B) + d(B,C)?

Parte B. Un banco describe a sus clientes por edad e ingreso mensual:

Cliente	Edad (años)	Ingreso ($)
P1	25	40.000
P2	60	40.500
P3	28	43.000
P4	45	70.000

1. Sin normalizar, calcular la distancia Euclídea de P1 a P2 y de P1 a P3. ¿Qué cliente queda más cerca de P1?
2. Normalizar ambas variables con min-max y repetir el cálculo. ¿Cambia el cliente más cercano?
3. ¿Qué variable dominaba la distancia antes de normalizar y por qué? ¿Qué consecuencia tendría eso en un K-Means?

Ejercicio 2: variables binarias y categóricas

Repaso. Para dos objetos i y j con variables binarias se cuentan q (ambos 1), r (i = 1, j = 0), s (i = 0, j = 1) y t (ambos 0). En variables binarias asimétricas, los 0-0 no aportan información y se descartan:

d(i, j) = (r + s) / (q + r + s)

sim Jaccard(i, j) = q / (q + r + s) = 1 − d(i, j)

Para p variables categóricas, con m coincidencias:

d(i, j) = (p − m) / p

Parte A. Un supermercado registra qué productos compró cada cliente en el mes (1 = compró, 0 = no compró):

Cliente	Pan	Leche	Café	Yerba	Vino	Pañales
Ana	1	0	1	1	0	0
Beto	1	1	1	0	0	0

Cliente	Pan	Leche	Café	Yerba	Vino	Pañales
Caro	0	0	0	1	1	0
Dani	1	0	1	1	1	0

1. Armar la tabla de contingencia (q, r, s, t) para cada uno de los 6 pares de clientes.
2. Calcular la distancia de Jaccard para cada par y armar la matriz de distancias.
3. ¿Qué par es el más parecido? ¿Cuál es el más distinto?
4. Calcular también la distancia que incluye los 0-0, (r + s) / (q + r + s + t), para Ana-Beto. ¿Por qué no conviene contar como "parecidos" a dos clientes que no compraron pañales?

Parte B. Cuatro clientes descriptos por tres variables categóricas:

Cliente	Zona	Medio de pago	Segmento
1	Norte	Tarjeta	Joven
2	Sur	Efectivo	Joven
3	Norte	Tarjeta	Adulto
4	Sur	Tarjeta	Adulto

1. Calcular la matriz de distancias completa con d = (p − m) / p.
2. ¿Qué pares quedan empatados como los más cercanos? ¿Qué problema le genera ese empate a un algoritmo jerárquico?

Ejercicio 3: K-Means a mano

Repaso. K-Means alterna dos pasos hasta que las asignaciones dejan de cambiar: asignar cada punto al centroide más cercano y recalcular cada centroide como la media de sus puntos. La calidad se mide con la suma de cuadrados dentro de los clusters (SSE o withinss):

SSE = Σ (k = 1 … K) Σ (x ∈ C□) ‖x − μ□‖²

donde μ□ es el centroide del cluster C□: para cada cluster se suman los cuadrados de las distancias de sus puntos al centroide, y después se suman los K clusters.

Datos. Siete observaciones con dos variables:

Punto	X1	X2
A	1,0	1,0
B	1,5	2,0
C	3,0	4,0
D	5,0	7,0

Punto	X1	X2
E	3,5	5,0
F	4,5	5,0
G	3,5	4,5

Consigna. Aplicar K-Means con K = 2, usando A y D como centroides iniciales.

1. Graficar los 7 puntos en papel cuadriculado y marcar los centroides iniciales.
2. Iteración 1: armar una tabla con la distancia Euclídea de cada punto a cada centroide y asignar cada punto a un cluster. Atención: un punto queda empatado; aplicar la regla de desempate de las consignas generales.
3. Recalcular los centroides y dibujarlos en el gráfico.
4. Repetir los pasos 2 y 3 hasta que ninguna asignación cambie. ¿Cuántas iteraciones hicieron falta?
5. Calcular la SSE de la solución final y la de cada cluster por separado.
6. Si el empate del paso 2 se hubiera resuelto a favor del cluster 2, ¿el resultado final cambia? Justificar.

Ejercicio 4: óptimos locales y elección de K

Repaso. K-Means converge siempre, pero no necesariamente a la mejor solución: el resultado depende de los centroides iniciales. Por eso se corre varias veces con inicializaciones distintas y se conserva la de menor SSE. Para elegir K, el método del codo busca el punto donde agregar un cluster deja de reducir mucho la SSE.

Parte A. Cuatro puntos en las esquinas de un rectángulo: P1 = (0, 0), P2 = (0, 2), P3 = (6, 0) y P4 = (6, 2). Se aplica K-Means con K = 2.

1. Inicialización 1: centroides en (0, 1) y (6, 1). Ejecutar el algoritmo hasta converger y calcular la SSE.
2. Inicialización 2: centroides en (3, 0) y (3, 2). Ejecutar el algoritmo hasta converger y calcular la SSE.
3. ¿Por qué el algoritmo se detiene en la inicialización 2 si la solución es peor? Relacionarlo con el concepto de óptimo local.
4. Proponer una estrategia práctica para evitar quedarse con la solución de la inicialización 2.

Parte B. Una empresa describe a 60 clientes con dos variables y corre K-Means para distintos valores de K, quedándose en cada caso con la mejor de 50 inicializaciones:

K	SSE
1	865,6
2	379,5
3	30,1

K	SSE
4	24,9
5	20,3
6	15,6

1. Graficar la SSE en función de K (curva del codo).
2. Calcular cuánto baja la SSE al pasar de K a K + 1, en valor absoluto y en porcentaje.
3. ¿Qué K elegirían según el método del codo? Justificar con los números del punto anterior.
4. ¿Por qué no conviene elegir el K que minimiza la SSE? ¿Qué pasaría con K = 60?
5. En el Ejercicio 3, la SSE con K = 2 fue 8,53. ¿Tiene sentido compararla con los valores de esta tabla? ¿Por qué?

Ejercicio 5: jerárquico aglomerativo con single y complete linkage

Repaso. El método aglomerativo empieza con cada observación como un cluster y en cada paso fusiona los dos clusters más cercanos. El linkage define qué significa "más cercanos":

Single: $d(A, B) = \min \{ d(x, y) : x \in A, y \in B \}$

Complete: $d(A, B) = \max \{ d(x, y) : x \in A, y \in B \}$

donde A y B son dos clusters.

Datos. Matriz de distancias entre cinco objetos:

	A	B	C	D	E
A	0				
B	2	0			
C	5,5	5	0		
D	10	9	4	0	
E	9	8	7	3	0

Parte A: single linkage.

1. Encontrar el par más cercano, fusionarlo y anotar la altura de fusión.
2. Recalcular la matriz de distancias con el nuevo cluster usando single linkage. Escribir la matriz completa en cada paso.
3. Repetir hasta que quede un único cluster.
4. Dibujar el dendrograma con las alturas de fusión en el eje vertical.

Parte B: complete linkage.

1. Repetir los pasos de la Parte A con complete linkage.

2. Dibujar el dendrograma.

Parte C: comparación.

1. Los dos primeros pasos coinciden. ¿En qué paso se separan los resultados y por qué?
2. ¿Con qué grupo termina C en cada caso? Explicarlo mirando solo la fila de C en la matriz original.
3. Cortar cada dendrograma para obtener 2 clusters. ¿Qué agrupamiento resulta en cada caso?
4. Comparar las alturas de la última fusión. ¿Por qué complete linkage siempre da alturas mayores o iguales que single?

Ejercicio 6: average linkage y coeficiente de silueta

Repaso. Average linkage usa el promedio de todas las distancias entre los puntos de ambos clusters. El coeficiente de silueta mide qué tan bien asignada está cada observación i: a(i) es su distancia promedio a los demás puntos de su cluster y b(i), su distancia promedio al cluster vecino más cercano.

Average: $d(A, B) = [\Sigma (x \in A) \Sigma (y \in B) d(x, y)] / (|A| \cdot |B|)$

$s(i) = (b(i) - a(i)) / máx\{ a(i), b(i) \}$

donde |A| es la cantidad de puntos del cluster A.

Usar la misma matriz de distancias del Ejercicio 5.

Parte A: average linkage.

1. Aplicar el algoritmo aglomerativo con average linkage hasta obtener un único cluster. Escribir la matriz en cada paso.
2. Dibujar el dendrograma y compararlo con los del Ejercicio 5. ¿A cuál de los dos se parece en la estructura? ¿Y en las alturas?
3. Cortar el dendrograma en 2 clusters.

Parte B: silueta de una observación. Se comparan las dos soluciones de 2 clusters obtenidas en el Ejercicio 5:

- Solución S (single): {A, B} y {C, D, E}.
- Solución C (complete): {A, B, C} y {D, E}.

1. Calcular a(C), b(C) y s(C) en la solución S.
2. Calcular a(C), b(C) y s(C) en la solución C.
3. Interpretar el signo de s(C) en cada caso. ¿En qué solución está mejor asignado C?
4. Calcular s(i) para las cinco observaciones en ambas soluciones y el promedio de cada una.
5. Los promedios dan casi lo mismo. ¿Qué dice eso sobre usar solo la silueta promedio para comparar soluciones? ¿Qué aporta mirar el gráfico de ancho de silueta?